



MAC LLM CLUSTER & AI GATEWAY

Private AI Infrastructure on Apple Silicon

On-Premise • Open-Source • Fully Private

Member

1. **นายกษิตศ บุญนำ**

Email: kasidit.boo@ku.th

(ปาล์ม)

2. **นายมุฮัมหมัดฮานีฟ เพ็งมุซอ**

Email: muhammadhanif.p@ku.th

(ฮานีฟ)

3. **นายต่อบุญฤทธิ์ อีสระภักดิ์รัตน์**


Email: torbunyarit.is@ku.th

(ต่อ)



WHY NOT JUST USE CHATGPT OR OTHER CLOUD BASED LLM?

	Cloud AI	Our Platform
Data Location	External server	Your hardware
Cost	Per query	One-time
Internet Needed	Yes	No
Data Privacy	Risky	Guaranteed






RUN AI LOCALLY. KEEP DATA PRIVATE

- 3 Mac Studio M4 Max running 24/7
- 30B+ parameter models - same scale as cloud AI
- Zero data leaves the local network
- Fully open-source - no license fees, no subscriptions


PROJECT OBJECTIVES

1. Develop and test on-premise LLM models, reducing cloud reliance
 2. Enhance data security by keeping all data private (Data Privacy)
 3. Support AI applications: ChatOps, log analysis, automated reports (Automation)
- 

HARDWARE

3× Apple Mac Studio M4 Max

14-core CPU, 32-core GPU, 16-core Neural Engine
36GB unified memory, 512GB SSD storage



TL-SX3008F

JetStream 8-Port 10GE SFP+ L2+ Managed Switch





Why Apple Silicon is Perfect for Running LLM

Unified Memory (36GB shared pool)


CPU and GPU share the same RAM → no copying data between them.
A 30-33B parameter model needs ~32GB and fits completely with room to spare. Traditional systems need expensive 80GB GPUs.

Apple Neural Engine (16 cores)

Dedicated AI acceleration hardware built into the chip. Speeds up the matrix math that powers AI models, reducing GPU load.


410 GB/s Memory Bandwidth

4-8× faster than standard RAM. Model weights (20-30GB files) load in seconds, not minutes. Tokens generate smoothly.



SYSTEM ARCHITECTURE

SYSTEM ARCHITECTURE — FULL REQUEST FLOW




AI MODELS

The Right Model for Every Task

Node	Model	Best For
IIm-01	Phi-4 14B	Fast, general questions
IIm-02	Qwen 2.5 32B	Complex reasoning
IIm-03	Qwen 2.5 32B ↔ DeepSeek Coder 33B	Auto-switches for code
All 3	Qwen3.6-35B (Exo)	Maximum power, 100-page context



WEB UI

interaction with user



RAG

Answer From Your Own Documents



Qdrant + BAAI/bge-m3 + PyMuPDF + python-docx + pytesseract + Pillow

PRIVACY FILTER (PII)

Personal Data Never Reaches the AI

Input	What AI Sees
สมชาย มีสุข อนุมัติแล้ว	[PERSON] อนุมัติแล้ว
081-234-5678	[PHONE_NUMBER]
somchai@company.com	[EMAIL_ADDRESS]
4111-1111-1111-1111	[CREDIT_CARD]

Microsoft Presidio + spaCy NLP

DISTRIBUTED INFERENCE (EXO)

3 Macs for 1 Powerful AI




The EXO interface displays a list of recommended models for the cluster. The table shows the following models:

Search models...		34GB/108GB		
All	RECOMMENDED FOR YOUR CLUSTER - fits in available memory			
Hub	GPT-OSS 120B	66GB	☆	i
Kimi	> Qwen3.5 122B A10B	4 variants (65GB-228GB)	☆	i
Qwen	> Qwen3 Next 80B	4 variants (44GB-83GB)	☆	i
GLM	> Qwen3.6 35B A3B	4 variants (19GB-65GB)	✓	☆
MiniMax	> Qwen3.5 35B A3B	2 variants (19GB-35GB)	☆	i
DeepSeek	> Qwen3 30B	2 variants (16GB-31GB)	☆	i
OpenAI	> GLM 4.7 Flash	4 variants (18GB-32GB)	☆	i
Meta	> Gemma 4 31B	4 variants (17GB-58GB)	☆	i
Google	> NVIDIA Llama-3.1-Nemot...	3 variants (37GB-131GB)	☆	i
	> NVIDIA Nemotron-3-Nano...	7 variants (16GB-59GB)	☆	i
	> Qwen3 6 27B	3 variants (15GB-51GB)	☆	i

Auto-activated on demand • Auto-unloads after 5 min idle

MONITORING

Full Visibility Across All 3 Nodes




Prometheus + Grafana + psutil + powermetrics



AUTOMATION

Possible with current setup

Service	Schedule	What It Does	Model
Log Analyzer	Every hour	Reads error logs → finds root cause	Phi-4
Report Generator	Every day	Cluster health summary	Phi-4
Code Reviewer	On demand	Reviews files or git diffs	DeepSeek Coder







SECURITY

Multiple Layers of Protection

Layer	What We Do
Network	Internal network only (192.168.10.0/24) SSH key-based auth
Transport	HTTPS / TLS on all external endpoints (port 8443) Rate limiting 200 req/hour
Application	PII auto-scrubbing on every request Optional API key validation · Full audit log
Data	Nothing transmitted externally Secrets excluded from version control







SHOWCASE

```
llm-01@llm-01 ~ % curl -s http://llm-01.local:8082/v1/chat/completions \
-H "Authorization: Bearer x" \
-H "Content-Type: application/json" \
-d '{"model":"phi4:latest","messages":[{"role":"user","content":"สรุปหลักการและวัตถุประสงค์ของ GenEd อย่างละเอียด พร้อมบอกสิ่งที่นิสิตควรรู้ และ บอกจำนวนหน่วยที่ต้องเรียนด้วย"}],"use_rag":true,"scrub_pii":true,"show_log":true}' \
| python3 ~/mac-llm-cluster/scripts/gateway/llm-parse.py
```

```
[1] Request received model=phi4:latest rag=True pii=True
[2] RAG injected context added from Qdrant
[3] PII scrubbed Presidio applied
[4] Forwarding → LiteLLM :8083 model=phi4:latest
[5] Done
```

****หลักการและวัตถุประสงค์ของวิชาศึกษาทั่วไป (GenEd):****

- **พลเมืองที่ดำรงตนและมีจริยธรรม**:**
 - วิชาศึกษาทั่วไปมุ่งเน้นการสร้างบุคคลที่เป็นพลเมืองที่ดำรงตนอย่างแข็งแกร่ง มีจริยธรรม และยึดมั่นในสิ่งที่ถูกต้อง โดยเป็นผู้คนที่รู้คุณค่าและรักษาชาติกำเนิดไว้ พร้อมร่วมมือร่วมพลังเพื่อสร้างสรรค์และพัฒนาสังคมอย่างยั่งยืน
- **การสร้างบุคลิกภาพที่มีคุณค่า**:**
 - วิชาศึกษาเหล่านี้มีจุดประสงค์ในการส่งเสริมการพัฒนาบุคลิกภาพของนักเรียน ทำให้พวกเขาเติบโตเป็นพลเมืองที่มีคุณค่าของสังคม
- **การจัดการศึกษา**:**
 - แม้ว่า GenEd อาจจะถูกจำแนกเป็นรายวิชาหรือลักษณะบูรณาการใดๆก็ได้ แต่ต้องเป็นส่วนหนึ่งของหมวดวิชาที่มีจุดประสงค์ชัดเจนตามประกาศคณะกรรมการมาตรฐานการอุดมศึกษา
- **วิธีการสอนและการเรียน**:**
 - การใช้เทคโนโลยีสารสนเทศในการสอน
 - การสังเกตพฤติกรรมของนิสิต
 - การระดมสมองและส่งเสริมความสม่ำเสมอในการเข้าร่วมกิจกรรมทั้งในและนอกชั้นเรียน
 - การพัฒนาความรับผิดชอบและการประเมินตนเองของนิสิต

****สิ่งที่นิสิตควรรู้**:**


- วิชา GenEd เป็นหมวดหนึ่งในหลักสูตรการศึกษาระดับปริญญาตรีที่ถือเป็นพื้นฐานสำคัญสำหรับการพัฒนาบุคลิกภาพและความรู้ทั่วไป
- การเรียนเหล่านี้ไม่เพียงแต่จะช่วยในด้านประสบการณ์การศึกษาแต่อย่างใด แต่ยังมีบทบาทสำคัญในการเตรียมพร้อมนักเรียนสำหรับชีวิตอยู่ในสังคม
- เป้าหมายของ GenEd คือให้นักเรียนได้รับประสบการณ์ที่หลากหลายและพัฒนาทักษะพื้นฐาน เช่น การสื่อสาร ความรับผิดชอบ และประเมินตนเอง

****จำนวนหน่วยกิตที่ต้องเรียน**:**

- นักศึกษาระดับปริญญาตรีควรทำ GenEd ในลักษณะที่มีจำนวนหน่วยกิตไม่น้อยกว่า ****24 หน่วยกิต**** ส่งผลให้ได้การประเมินผลที่ชัดเจนและสะท้อนถึงความสำเร็จในการบรรลุผลการเรียนของนักเรียนตามวัตถุประสงค์ที่กำหนด

GenEd เป็นพื้นฐานที่ช่วยให้นักเรียนไม่เพียงแต่ได้ความรู้และทักษะเฉพาะของวิชาเลือก แต่ยังพัฒนาบุคลิกภาพและความสามารถในการเป็นพลเมืองที่ดีและมีคุณค่าได้ดียิ่งขึ้น.

SHOWCASE



SHOWCASE

```
llm-01@llm-01 ~ % curl -s http://llm-01.local:8082/v1/chat/completions \
-H "Authorization: Bearer x" \
-H "Content-Type: application/json" \
-d '{"model":"qwen2.5:32b-instruct-q4_K_M","messages":[{"role":"user","content":"สรุปหลักการและวัตถุประสงค์ของ GenEd อย่างกระชับ พร้อมบอกสิ่งที่นิสิตควรรู้ และ บอกจำนวนหน่วยกิจต้องเรียนด้วย"}],"use_rag":true,"scrub_pii":true,"show_log":true}' \
| python3 ~/mac-llm-cluster/scripts/gateway/llm-parse.py
```

```
[1] Request received  model=qwen2.5:32b-instruct-q4_K_M rag=True pii=True
[2] RAG injected      context added from Qdrant
[3] PII scrubbed     Presidio applied
[4] Forwarding       → LiteLLM :8083 model=qwen2.5:32b-instruct-q4_K_M
[5] Done
```

GenEd (General Education) ในเอกสารที่ให้มามีเป้าหมายในการผลิตบุคคลที่เป็นพลเมืองมีคุณธรรมและยึดถือในสิ่งที่ถูกต้อง มีความรู้คุณค่าและศักดิ์ศรีของชาติกำเนิด สามารถทำงานร่วมกับผู้อื่นเพื่อพัฒนาสังคมอย่างยั่งยืน เป็นพลเมืองที่มีคุณค่าในสังคม

วัตถุประสงค์ของ GenEd มีดังต่อไปนี้:

- สร้างความเข้มแข็งในการดำรงตนเป็นพลเมืองที่ดี
- ส่งเสริมจริยธรรมและค่านิยมที่ยึดมั่นในสิ่งที่ถูกต้อง
- พัฒนาความสามารถในการรู้คุณค่าและความสำคัญของชาติกำเนิด
- กระตุ้นให้มีความร่วมมือและรวมพลังเพื่อสร้างสรรค์และพัฒนาสังคมอย่างยั่งยืน

สำหรับนิสิต ควรทราบว่า GenEd เป็นส่วนสำคัญของหลักสูตรที่ช่วยให้ศึกษาและเข้าใจถึงความเป็นพลเมืองที่ดี จริยธรรม และการพัฒนาสังคม ซึ่งจะช่วยเสริมสร้างความสามารถในการทำงานร่วมกับผู้อื่นในอนาคต

จำนวนหน่วยกิตที่ควรศึกษาตามข้อกำหนดคือไม่น้อยกว่า 24 หน่วยกิต และต้องมีการวัดและประเมินผลที่สะท้อนถึงการบรรลุผลสำเร็จในการเรียนรู้ของนิสิตในด้านต่าง ๆ ให้ชัดเจนตามเกณฑ์มาตรฐานหลักสูตรระดับปริญญาตรี พ.ศ. 2565.

นอกจากนี้ การวัดและประเมินผลอาจครอบคลุมการสังเกตพฤติกรรมและการแสดงออกของนิสิตในกิจกรรมต่าง ๆ ทั้งรายบุคคลและกลุ่ม การสม่่าเสมอในการเข้าร่วมกิจกรรม และความรับผิดชอบในงานหรือกิจกรรมที่ได้รับมอบหมาย.

prompt=1002 tok | completion=579 tok | total=1581 tok | time=57.6s | speed=10.1 tok/s

SHOWCASE



SHOWCASE

```
llm-01@llm-01 mac-llm-cluster % curl -s http://llm-01.local:8082/v1/chat/completions \
-H "Authorization: Bearer x" \
-H "Content-Type: application/json" \
-d '{"model": "exo:Qwen3.6-35B-A3B-8bit", "messages": [{"role": "user", "content": "สรุปหลักการและวัตถุประสงค์ของ GenEd อย่างละเอียด พร้อมบอกสิ่งที่นิสิตควรรู้ และ บอกจำนวนหน่วยกิตต้องเรียนด้วย"}], "use_rag": true, "scrub_pii": true, "show_log": true}' \
| python3 ~/mac-llm-cluster/scripts/gateway/llm-parse.py
```

```
[1] Request received model=exo:Qwen3.6-35B-A3B-8bit rag=True pii=True
[2] RAG injected context added from Qdrant
[3] PII scrubbed Presidio applied
[4] Forwarding → Exo :5678 model=mlx-community/Qwen3.6-35B-A3B-8bit
[5] Done
```

จากเอกสาร **“”**เล่มหมวดวิชาศึกษาทั่วไป มก. พ.ศ. 2567**””** ที่ให้มา สามารถสรุปหลักการ วัตถุประสงค์ สิ่งนิสิตควรรู้ และจำนวนหน่วยกิตได้ดังนี้ครับ

♦ หลักการและวัตถุประสงค์ของวิชาศึกษาทั่วไป (GenEd)

- ”วัตถุประสงค์หลัก:”** มุ่งผลิตบัณฑิตและนักศึกษาให้เป็นบุคคลที่ดำรงตนเป็น **”“พลเมืองที่เข้มแข็ง มีจริยธรรม ยึดมั่นในสิ่งที่ถูกต้อง รู้คุณค่าและรักษาชาติกำเนิด”**”” พร้อมทั้งร่วมมือร่วมพลังเพื่อสร้างสรรค์และพัฒนาสังคมอย่างยั่งยืน และเป็น **”“พลเมืองที่มีคุณค่าของสังคม”**””
- ”หลักการดำเนินการ:”** สามารถจัดโครงสร้างวิชาในลักษณะใดก็ได้ตามความเหมาะสม ไม่ว่าจะเป็นการแยกเป็นรายวิชาเฉพาะ หรือการจัดในรูปแบบบูรณาการระหว่างศาสตร์ต่าง ๆ เพื่อส่งเสริมให้ผู้เรียนบรรลุผลลัพธ์การเรียนรู้ที่สอดคล้องกับปรัชญาและวัตถุประสงค์ของการจัดการศึกษาหมวดวิชา
- ”หลักการประเมินผล:”** ต้องมีการออกแบบการวัดและประเมินผลที่สะท้อนการบรรลุผลลัพธ์การเรียนรู้ของผู้เรียนอย่างชัดเจน โดยอ้างอิงตามประกาศคณะกรรมการมาตรฐานการอุดมศึกษา เรื่อง เกณฑ์มาตรฐานหลักสูตรระดับปริญญาตรี พ.ศ. 2565

♦ สิ่งที่นิสิตควรรู้

- ”เป้าหมายของการเรียน:”** GenEd ไม่ใช่เพียงการเรียนข้ามสาขา แต่เป็นการพัฒนาภาวะผู้นำ จริยธรรมพลเมือง และจิตสำนึกสาธารณะเพื่อเป็นส่วนหนึ่งของการขับเคลื่อนสังคมอย่างยั่งยืน
- ”รูปแบบการเรียนรู้:”** จะต้องร่วมกิจกรรมทั้งแบบรายบุคคลและรายกลุ่ม โดยมีการนำเทคโนโลยีสารสนเทศมาสนับสนุนกระบวนการเรียนรู้และการสื่อสาร
- ”แนวทางการประเมินผล:”** จะถูกประเมินผ่านหลายมิติ ได้แก่
 - การสังเกตพฤติกรรมและการแสดงออกขณะทำกิจกรรม (ทั้งกลุ่มและเดี่ยว)
 - ความสม่ำเสมอในการเข้าร่วมกิจกรรมในและนอกชั้นเรียน
 - ความรับผิดชอบในงานหรือกิจกรรมที่ได้รับมอบหมาย
 - การระดมสมองและการมีส่วนร่วมกับเพื่อนร่วมชั้น
 - การประเมินตนเองและประเมินโดยเพื่อนร่วมชั้น (Peer & Self Assessment)
 - การส่งรายงานความก้าวหน้าและการจัดทำรายงานสรุปผลโครงการ
- ”ข้อควรเตรียมตัว:”** นิสิตควรฝึกทักษะการทำงานร่วมกัน การคิดวิเคราะห์ผ่านกระบวนการระดมสมอง ทักษะการเขียนรายงานวิชาการ/โครงการ และมีความซื่อสัตย์ทางการประเมินตนเองและเพื่อนร่วมชั้น

♦ จำนวนหน่วยกิตที่ต้องเรียน

ตามเกณฑ์มาตรฐานหลักสูตรระดับปริญญาตรี พ.ศ. 2565 ที่อ้างอิงในเอกสาร **”หมวดวิชาศึกษาทั่วไปจะต้องมีจำนวนหน่วยกิตรวมไม่น้อยกว่า 24 หน่วยกิต”**

✖ **หมายเหตุ:** ข้อมูลดังกล่าวสรุปจากเอกสาร **”เล่มหมวดวิชาศึกษาทั่วไป มก. พ.ศ. 2567”** โดยมีการปรับแก้ข้อผิดพลาดจากการสแกนเอกสารเดิม (เช่น คำที่สะกดผิดหรือตัดคำตกหล่น) เพื่อให้สอดคล้องกับบริบททางการศึกษาระดับอุดมศึกษาไทยครับ* หากต้องการรายละเอียดเฉพาะรายวิชาหรือโครงสร้างหลักสูตรปีการศึกษาอื่น สามารถระบุเพิ่มเติมได้ครับ

prompt=547 tok | completion=2309 tok | total=2856 tok | time=37.7s | speed=61.3 tok/s

SHOWCASE

```
llm-01@llm-01 mac-llm-cluster % bash ~/mac-llm-cluster/scripts/exo/exo-roll-start.sh
[
=== Exo Model CLI ===
]

Model: mlx-community/Qwen3.6-35B-A3B-8bit
Start: roll start

Checking if model is already loaded...
Placing model instance across cluster nodes...
Loading model shards across nodes (~30s)...

✅ Model loaded and ready (30s)

Roll start - mlx-community/Qwen3.6-35B-A3B-8bit
Sending short inference request (max 50 tokens)...


Model will be fully operational within 60s after this message.
llm-01@llm-01 mac-llm-cluster % curl -s http://llm-01.local:8082/v1/chat/completions \
-H "Authorization: Bearer x" \
-H "Content-Type: application/json" \
-d '{"model": "exo:Qwen3.6-35B-A3B-8bit", "messages": [{"role": "user", "content": "สรุปหลักการและวัตถุประสงค์ของ GenEd อย่างกระชับ พร้อมบอกถึงที่นิสิตควรรู้ และ บอก จำนวนหน่วยกิตที่ต้องเรียนด้วย"}], "use_rag": true, "scrub_pii": true, "show_log": true}' \
| python3 ~/mac-llm-cluster/scripts/gateway/llm-parse.py

[[1] Request received model=exo:Qwen3.6-35B-A3B-8bit rag=True pii=True
[2] RAG injected context added from Qdrant
[3] PII scrubbed Presidio applied
[4] Forwarding → Exo :5678 model=mlx-community/Qwen3.6-35B-A3B-8bit
[5] Done
```


```
llm-01@llm-01 mac-llm-cluster % bash ~/mac-llm-cluster/scripts/exo/exo-unload.sh

=== Exo Unload ===
[
Model: mlx-community/Qwen3.6-35B-A3B-8bit
]

Resolving instance ID...
✅ Instance ID: b8e380b0-2792-42b9-9ccd-1c5ab74b3319
Sending DELETE request to exo API...
Command received.
✅ Instance deleted - model unloaded from GPU
llm-01@llm-01 mac-llm-cluster % █
```



SHOWCASE



PROJECT TIMELINE

May 5-8: Hardware & Foundation

- Mac Studio delivered, network switch installed
- Ollama, macOS hardening

May 9-11: Infrastructure

- Base structure created, SSH configuration
- 3-node cluster setup (scripts, configs, monitoring)
- Prometheus + Grafana metrics pipeline

May 12-15: Distributed Inference (Exo)

- Exo distributed mode for Qwen3.6-35B across all 3 nodes
- Fixed peer discovery, GPU metrics, model loading
- Stress tested by generating story
- Pinned llm-01 as coordinator

May 21-22: AI Gateway & Services

- LiteLLM proxy for model routing
- Presidio PII filter integrated
- Web UI (React + Express)
- Queue manager, CLI tools

May 24: Core Platform Ready

- Exo + RAG + PII pipeline complete
- Routing finalized: Exo direct (:5678), standard models via LiteLLM (:8083)
- Documentation & presentation materials





THANKYOU